

## < CHIP 5주차 선각 레포트 >

- GPU 없인 AI 못 한다고? 다시는 CPU를 무시하지 말라...

KJ-8-301-05 김재현

한때 인공지능은 공상과학 영화 속에서나 보던 신기루 같은 존재였다. 그런데 어느샌가 우리는 'AI야, 오늘 날씨 어때?'라며 자연스럽게 기계와 대화를 하고, 스마트폰으로 고양이 사진을 분류하며 '이건 텍시도냥, 저건 치즈냥' 구별까지 맡기고 있다. 이 놀라운 AI 열풍의 배후에는 우리가 잘 아는 주역이 있다. 바로 GPU, 그래픽 처리 장치다.

사실 GPU는 원래 게임 그래픽이나 잘 뿌려주는 칩이었다. 그런데 웬걸? 이 녀석이 AI를 만났더니 난데없이 천재 수학자로 각성한 것이다. 딥러닝의 핵심은 엄청난 양의 곱하기와 더하기인데, GPU는 수천 개의 코어로 이걸 동시에 똑딱똑딱 해내니 AI 연구자들의 눈에 하트가 떠오를 수밖에. 특히 2012년, 'AlexNet'이라는 딥러닝 모델이 GPU의 힘을 빌려 이미지 인식 대회에서 다른 모델들을 쓸어버렸을 때, 모든 연구자들은 속으로 외쳤다. "아... 이제는 GPU의 시대구나."

그 이후 AI 연구는 말 그대로 GPU의, GPU에 의한, GPU를 위한 전성시대에 돌입했다. 연구실, 스타트업, 빅테크 가릴 것 없이 모두 GPU에 목을 매달았다. 하지만... 언제부턴가 다들 한마디씩 하기 시작했다. "야, 근데 GPU 너무 비싸지 않냐?"라고.

맞다. GPU는 비싸다. 엄청 비싸다. 심지어 요즘은 수급도 불안정해서, 돈이 있어도 못 구하는 사태도 종종 벌어진다. 게다가 소형 기기나 엣지 디바이스에선 전력도 너무 많이 먹는다. 노트북에 GPU 뽐뽐하게 넣어놨자 팬 돌아가며 비행기 출항 소리 나는 건 덤이다. 이쯤 되면 이렇게 묻고 싶어진다. "아니, AI가 꼭 GPU 있어야만 돌아가는 거야? CPU는 대체 뭐하냐고?"

여기서 판을 뒤집는 반전이 시작된다. 최근 몇몇 연구자들이 CPU 기반으로도 AI를 '꽤나 그럴싸하게' 돌리는 방법을 찾아내기 시작했다. 예컨대 Meta가 공개한 LLaMA2 7B 같은 경량 모델을 스마트폰이나 소형 장비에서 CPU만으로 실행했더니, 잘만 튜닝하면 GPU보다 효율이 좋다는 실험 결과도 나왔다. (심지어 전기도 덜 먹는다!)

이유는 간단하다. AI도 다이어트 중이다. 요즘 AI 모델은 '양자화(quantization)', '프루닝(pruning)', '디스틸레이션(distillation)' 같은 기술로 몸집을 확 줄였다. 마치 예전엔 헬창

모델만 있었다면, 이제는 마른 체형의 마라토너도 무대에 오를 수 있는 세상이 된 셈이다. 무작정 뽐뽐한 연산력이 아닌, ‘적절히 가볍고 똑똑한 모델’이 사랑받는 시대가 왔다.

게다가 소프트웨어도 영리해졌다. ONNX, TVM 같은 프레임워크가 등장하면서 모델 최적화는 말 그대로 버튼 한 번이면 딱딱. 심지어 애플의 Neural Engine이나 삼성의 NPU처럼, 모바일 칩셋에도 AI 가속 유닛이 탑재되며 'GPU가 없으면 아무것도 못 해요'라는 변명이 점점 설 자리를 잃고 있다.

우리 일상에서도 이런 변화는 체감된다. 아이폰은 사진 찍을 때 자동으로 배경을 흐리고, 음성인식을 실시간으로 처리한다. 대부분의 연산이 GPU 없이 CPU 또는 전용 NPU에서 벌어진다. ChatGPT 같은 대형 모델을 모바일이나 저가형 랩탑에서 돌리는 건 아직 어렵지만, 뉴스 요약, 간단한 이미지 분류, 맞춤법 검사 등은 이미 CPU만으로 충분히 커버되는 시대다.

물론 훈련(training)은 여전히 GPU의 철권통치가 유지되고 있다. GPT-4 같은 대형 모델은 텐서 수천억 개를 돌리고 돌리며 태어난 괴물들이기 때문이다. 하지만 모델을 실제 서비스에서 사용하는 '추론(inference)' 단계에선 CPU의 활약이 점점 더 커지고 있다. 실제로 여러 기업들이 서버 코스트 절감을 위해 추론을 GPU → CPU로 옮기는 중이다.

그리고 이 흐름은 산업 전반으로 확산 중이다. 예컨대 자율주행 자동차의 경우, 차량 내 연산 장치는 전력 제한이 매우 크기 때문에 GPU보단 CPU, 혹은 전용 NPU 위주로 AI 추론을 수행하게 된다. IoT 센서 장비들, 웨어러블 헬스기기, 스마트 CCTV 등도 모두 마찬가지다. GPU는 감당이 안 되는 환경이 많다. 그래서 많은 기업들이 경량화된 TinyML 모델을 만들어 엣지 디바이스에서도 AI가 작동하도록 설계하고 있다.

게다가 클라우드 인프라에서도 CPU 기반 AI 추론은 무시 못 할 선택지가 되고 있다. AWS는 'Inferentia'라는 AI 추론 특화 하드웨어를 따로 출시했으며, Google은 Edge TPU 시리즈로 소형 기기용 AI 칩을 만들고 있다. 그동안 'GPU 아니면 AI 못 돌린다'는 사고방식은 더 이상 통하지 않는다.

AI는 GPU에서 시작됐지만, GPU에서 끝나지는 않을 것이다. 탈GPU 시대는 조용히 그러나 확실히 도래하고 있다. 앞으로는 이런 질문이 더 중요해질 것이다.

“이 문제에 GPU가 꼭 필요한가요?”

아니면 이렇게 바꿔 말해도 좋다. “지금 내가 가진 장비로도 AI 돌릴 수 있을까?”

답은 점점 'YES'로 수렴하고 있다. 어쩌면 조만간, 당신의 전자레인지나 냉장고도 '작은 AI'를 탑재할 수 있을지도 모른다.

---

## 참고문헌

1. C. Wang, S. Venkataramani, and Y. Yu, “LLM in a flash: Efficient large language model inference with limited memory,” *arXiv preprint arXiv:2309.17453*, Sep. 2023. [Online]. Available: <https://arxiv.org/abs/2309.17453>
2. T. Chen, Y. Wang, Z. Zhang, et al., “TVM: An automated end-to-end optimizing compiler for deep learning,” in *13th USENIX Symposium on Operating Systems Design and Implementation (OSDI 18)*, Oct. 2018, pp. 578–594.
3. S. Han, H. Mao, and W. J. Dally, “Deep compression: Compressing deep neural networks with pruning, trained quantization and Huffman coding,” in *International Conference on Learning Representations (ICLR)*, 2016.
4. M. Abadi, P. Barham, J. Chen, et al., “TensorFlow: A system for large-scale machine learning,” in *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)*, 2016, pp. 265–283.
5. N. P. Jouppi, C. Young, N. Patil, et al., “In-datacenter performance analysis of a tensor processing unit,” in *Proceedings of the 44th Annual International Symposium on Computer Architecture (ISCA)*, 2017, pp. 1–12.