

Computer Hardware & Industry Perspective

AI는 GPU없이 존재할 수 있는가?

서론

최근 인공지능(AI) 기술의 발전, 특히 딥러닝을 비롯한 머신러닝 기반 기술의 진보는 방대한 연산 능력에 크게 의존하며, 이 과정에서 GPU(Graphics Processing Unit)는 핵심적인 역할을 담당하고 있다. 본 보고서에서는 “AI는 GPU 없이 존재할 수 있는가?”라는 질문에 대한 답을 도출하기 위해, 우선 AI의 정의를 두 가지 유형으로 구분하고, 이 정의에 따라 GPU의 필요성을 분석하고자 한다. 이어서 GPU 없이 구현 가능한 기술들을 설명하고, 현재 GPU가 필수적인 대규모 AI 연산의 대표적인 예시를 들어 그 차이를 명확히 제시할 것이다. 마지막으로, 향후 GPU의 성능이 더욱 향상되어 초거대 AI 연산을 단시간 내에 처리할 수 있게 되었을 때, 새롭게 발생할 수 있는 또 다른 병목 현상에 대한 것으로 보고서를 마무리하고자 한다.

본론

AI를 어떻게 정의하느냐에 따라, GPU 없이 존재할 수 있는지에 대한 판단은 달라질 수 있다. 만약 AI를 간단한 모델을 학습시키거나, 추론만 수행하는 방식(예: 엣지 컴퓨팅), 또는 임베디드 시스템에서 동작하는 모델로 정의한다면 GPU 없이도 충분히 구현 가능한 것이기에 GPU 없이 존재할 수 있다고 말할 수 있을 것이다.

반면, 오늘날 우리가 일반적으로 언급하는 AI란 학습 방식을 근본적으로 바꾼 초거대 언어모델(LLM)이나, 대규모 데이터셋을 활용해 이미지를 자동으로 생성하는 등 높은 연산 성능을 요구하는 모델을 의미한다. 이러한 모델을 CPU만으로 학습할 경우 수십 년이 소요될 수 있으며, 수천 개의 GPU를 병렬로 활용했기 때문에 수주 또는 수개월 내에 학습이 가능했던 것이다. 결국 GPU 기술이 지금처럼 발전하지 않았다면, 우리가 현재 사용하고 있는 GPT 같은 모델은 수십 년 뒤에나 등장했을지도 모른다.

이후 본문에서는 이러한 논의를 바탕으로, AI의 정의에 따른 GPU 필요성, GPU 없이 가능한 기술들, GPU를 활용하는 주요 연산 예시, 그리고 향후 예상되는 병목 지점에 이르기까지 각 개념과 사례들을 간결하게 설명하고자 한다.

1. AI의 정의에 따른 GPU 필요성

AI는 복잡도와 규모에 따라 GPU의 필요성이 달라진다. 간단한 추론 모델은 CPU만으로 충분하지만, 초거대 모델은 GPU 없이 현실적인 학습이 어렵다.

- **경량 AI:** 저사양 환경에서도 동작 가능한 소형 AI 모델로, 모바일이나 IoT 기기에서 주로 활용된다(예: 음성 인식, 센서 이상 탐지).
- **초거대 AI:** 수백억~수천억 개의 파라미터를 갖고 대규모 데이터를 학습하는 모델로, 방대한 병렬 연산을 필요로 한다(예: GPT-4, PaLM, Stable Diffusion).

2. GPU 없이 가능한 경량 AI 기술 사례

엣지 컴퓨팅, TinyML 등의 기술은 GPU 없이도 CPU나 전용 프로세서로 효율적인 AI 구현을 가능하게 한다.

- **엣지 컴퓨팅**: 데이터를 클라우드 대신 현장에서 바로 처리하는 기술로, 저전력과 낮은 지연시간이 요구되는 환경에 적합하다(예: 스마트워치, 자율주행 자동차 센서 처리).
- **TinyML**: 매우 작은 연산량으로 초소형 MCU나 센서에서 AI를 구동하는 기술로, 배터리 기반 IoT 기기에 주로 적용된다(예: 음성 명령 기반 스마트 홈 디바이스).
- **임베디드 AI**: 소형 전자기기나 자동차 내부의 프로세서에 내장된 AI 모델로, 실시간 저지연 처리를 수행한다(예: 차량용 장애물 감지).

3. 초거대 AI 모델과 GPU의 필요성

초거대 AI 모델은 방대한 데이터셋과 병렬 연산으로 인해 GPU가 필수적이다. GPU가 없다면 현실적인 시간 내 학습이 불가능하다.

- **GPT-3/GPT-4**: 수백~수천억 개의 매개변수를 가진 초대형 언어모델로, 학습을 위해 수천 개의 GPU가 동원된다.
- **Stable Diffusion**: 고해상도 이미지 생성 모델로, 초기 학습 과정에서 수백 대의 GPU를 활용하여 빠르게 결과를 도출한다.
- **LLM(초거대 언어모델)**: 인간의 언어를 매우 정교하게 모방하는 모델로, 막대한 연산력과 데이터가 필수적이다(예: ChatGPT, Gemini, PaLM).

4. GPU를 대체할 수 있는 전용 AI 하드웨어 기술

GPU 외에도 TPU, PIM, FPGA, ASIC 등 특정 AI 작업에 특화된 하드웨어 기술들이 존재하며, 성능과 효율성 면에서 GPU를 보완하거나 대체할 수 있다.

- **TPU(Tensor Processing Unit)**: 구글이 개발한 전용 ASIC으로 행렬 연산에 특화되어 있으며, 특히 대규모 딥러닝 연산에서 GPU보다 효율적이다(예: 구글 검색 추천 알고리즘).
- **PIM(Processing-In-Memory)**: 메모리 내부에서 직접 연산을 수행하여 CPU와 메모리 간 병목현상을 제거하는 기술로, 전력 효율성과 속도가 매우 뛰어나다(예: SK하이닉스 GDDR6-AiM).
- **FPGA(Field-Programmable Gate Array)**: 프로그래밍 가능한 논리회로 칩으로, 특정 작업에 맞게 구조를 재구성할 수 있어 실시간 AI 처리에 유리하다(예: 마이크로소프트 Brainwave 프로젝트).
- **ASIC(Application Specific IC)**: 특정 용도로 설계된 전용 반도체로, 목적에 최적화된 AI 연산에서 탁월한 성능과 전력 효율을 발휘한다(예: Cerebras 웨이퍼 스케일 엔진).
- **엣지 AI 칩(Edge AI Chip)**: 저전력 환경에서 고효율 추론 연산을 수행하는 칩으로, 모바일이나 IoT 환경에 주로 적용된다(예: Google Coral Edge TPU, Apple Neural Engine).

5. GPU를 활용하는 대표적인 분야와 사용량 비교

GPU는 AI 외에도 다양한 분야에서 활용되며, 최근 AI 학습용 GPU의 수요 증가가 가장 두드러진다.

- **암호화폐 채굴**: 과거 GPU의 병렬 계산 능력을 이용하여 암호화폐 블록체인의 작업 증명을 처리하는 데 사용되었다(예: Ethereum GPU 채굴).
- **그래픽 렌더링**: GPU 본래 용도로, 실시간 고해상도 3D 그래픽 처리를 수행하며, 게임과 영화 제작 등에 널리 쓰인다(예: 고사양 게임, CGI 영화 제작).
- **과학 시뮬레이션(HPC)**: 고성능 컴퓨팅 분야에서 GPU를 이용해 대규모 수치 시뮬레이션과 과학 계산을 가속화한다(예: 기후 변화 모델링, 신약 개발 시뮬레이션).
- **영상 스트리밍/트랜스코딩**: 실시간 고해상도 영상을 처리하기 위해 GPU의 병렬 연산을 활

용하여 빠르게 동영상을 압축 및 변환한다(예: 유튜브, 넷플릭스 영상 처리).

결론

향후 GPU의 성능이 지속적으로 향상되어 초거대 AI 연산조차 단시간 내에 처리할 수 있는 시대가 도래한다면, 더 이상 연산 속도는 AI 개발과 활용의 병목이 되지 않을 것이다. 대신 새로운 병목은 인간 중심의 작업, 즉 **고품질 데이터를 수집하고 정제하는 과정, AI 결과의 신뢰성 및 윤리성 평가, 그리고 사용자 피드백을 반영한 모델 튜닝 및 정렬 작업** 등으로 이동할 가능성이 크다. 이는 단순한 계산력이나 하드웨어 성능만으로 해결할 수 없는 영역이며, AI가 사회 전반에 깊이 적용될수록 **인간의 판단, 책임, 기준 설정**이 AI 시스템의 효율과 신뢰도를 결정짓는 핵심 요소가 될 것이다. 결국 미래의 AI 병목은 기술 자체가 아니라, 그 기술을 어떻게 활용하고 통제할 것인가에 대한 **인간 중심의 문제**로 전환될 것이다.