

Computer Hardware & Industry Perspective

C.H.I.P 5주차 선각 Report
크래프톤 정글 8-10 백지원

AI는 GPU 없이 존재할 수 있는가?

1. 서론

인공지능(AI)은 현대 IT 기술 발전의 핵심 동력으로 자리 잡았다. 자연어 처리, 이미지 생성, 음성 인식, 자율주행 등 다양한 분야에서 AI는 필수 요소가 되었으며, 그 연산 기반은 주로 GPU(Graphics Processing Unit)에 의존해 왔다.

특히 대규모 딥러닝 모델을 학습하고 추론하는 데 필요한 대량의 병렬 행렬 연산은 GPU의 구조적 특성과 잘 맞아떨어진다. 이로 인해 GPU는 AI 기술의 '연산 엔진'으로 자리잡았고, 엔비디아(NVIDIA)는 AI 반도체 시장에서 독점적 지위를 구축하였다.

그러나 AI 생태계가 빠르게 확장됨에 따라, 고성능 GPU에만 의존하는 구조는 비용·에너지·접근성 측면에서 한계를 드러내고 있다. 이에 따라 GPU 없이도 AI 기능을 구현하고 실행하려는 시도들이 나타나고 있으며, 실제 성과를 거두는 사례도 등장하고 있다. 이 보고서는 AI가 GPU 없이 존재할 수 있는지에 대한 근본적 질문을 중심으로, 현재까지의 기술 진화 방향, 대안적 접근법, 그리고 실현 가능성을 종합적으로 분석한다.

2. 본론

2.1 왜 GPU가 AI에 필수적이었는가?

GPU는 본래 3D 그래픽 연산을 위해 개발된 병렬 연산 특화 하드웨어다. 수천 개의 코어를 동시에 활용하여 대규모 행렬 곱셈과 벡터 연산을 효율적으로 처리할 수 있다. 이는 인공신경망(ANN) 기반의 딥러닝 연산에서 매우 중요한 요소이다.

AI 모델 학습 시, 수백만 개의 가중치(weight)와 입력값(input)을 곱하고, 그 합을 구하는 작업이 반복된다. 이는 고전적인 CPU(수십 개 코어 수준)로는 순차 처리에 가까운 속도로 수행될 수밖에 없어, GPU 기반의 병렬 처리가 필수가 되었다.

2016년 알파고가 인간 바둑 프로를 이긴 사건 역시 수천 대의 GPU 기반 서버가 병렬로 작동한 결과이며, 이후 GPT, DALL-E, Stable Diffusion 등 생성형 AI 기술들은 모두 수천 개의 GPU 클러스터 위에서 학습되었다.

즉, GPU는 AI의 연산 집약적 특성을 감당할 수 있는 유일한 일반 상용 칩이었다.

그러나 이러한 구조는 대량의 전력 소모, 고비용 인프라, 독점화된 반도체 공급망 문제라는 구조적 한계를 낳게 되었다.

2.2 GPU 없는 AI: 새로운 대안의 등장

최근 AI 기술은 "GPU 중심에서 벗어난 온디바이스(On-Device) AI"와 "CPU 기반 AI 경량화 모델"을 중심으로 다각화되고 있다.

1) 페르소나AI의 초경량 AI (국내)

국내 스타트업 페르소나AI는 CPU만으로 작동하며, 인터넷 연결 없이도 언어 생성, 번역, 요약, 이미지 생성 등을 지원하는 한국어 특화 초경량 AI 모델을 구현하였다.

해당 모델은 초소형 노트북, 보안 디바이스, 군사 시스템 등에 탑재되어 클라우드 인프라 없이도 실시간 추론이 가능하다는 점에서 주목받고 있다.

이는 단순한 모델 축소가 아닌, 자체 개발한 AI 엔진과 파인튜닝된 파이프라인의 결합 결과

며, 보안·응답 속도·에너지 효율에서 높은 성능을 보이고 있다.

2) 인도 Ziroh Labs의 Kompact AI

인도 AI 기업 Ziroh Labs는 일반 CPU 기반 환경에서 AI 모델을 학습 및 실행할 수 있도록 한 플랫폼 'Kompact AI'를 개발하였다.

이 플랫폼은 인텔 제온 기반 노트북에서 Meta의 LLaMA 2, 알리바바 Qwen 등을 성공적으로 실행하며, AI의 '탈GPU화' 가능성을 입증하였다.

Ziroh는 GPU 구매가 어려운 중소기업 및 저소득 국가에 AI 접근성을 확대하기 위한 기술 철학을 강조하고 있다.

3) Microsoft BitNet

Microsoft는 최근 1비트 양자화 모델인 BitNet b1.58을 공개하였다. 해당 모델은 기존 16~32비트로 구성된 LLM 대비 수십 배 경량화되었으며, 일부 CPU 환경에서도 GPT-2 수준의 성능을 구현하였다.

이와 같은 초경량화 기술은 CPU, NPU, 엣지 디바이스에서도 AI 추론이 가능함을 보여준다.

2.3 기술적 고려사항 및 한계

GPU 없는 AI가 가능한 것은 사실이나, '범용적 대체' 수준은 아직 아니다.

학습 단계에서는 여전히 대규모 데이터와 고속 병렬 연산이 요구되므로 GPU 또는 TPU가 필요하다.

CPU 기반 AI는 대부분 **경량화된 추론(inference only)**에 집중되며, 모델 크기와 성능 간의 trade-off가 존재한다.

단일 디바이스 수준의 AI는 사전 학습된 모델 기반에서만 현실적으로 운영 가능하다.

그럼에도 불구하고, 하드웨어 기술과 소프트웨어 최적화가 병행된다면 AI의 '탈GPU화'는 제한적 영역에서 충분히 실현 가능하다.

3. 결론

AI는 그간 GPU에 의존하며 발전해 왔지만, 이는 필수조건이 아닌 최적 조건이었을 뿐이다.

최근 기술은 경량화, 모델 최적화, CPU·NPU 연산 최적화 등을 통해 GPU 없이도 AI가 가능한 환경을 만들고 있다.

페르소나AI, Ziroh Labs, Microsoft 등의 사례는 AI가 보다 작고 저렴한 디바이스로 확산될 수 있음을 보여준다.

특히 보안이 중요한 현장(군사, 금융), 연결성이 떨어지는 지역(비행기, 외딴 지역), 배터리 기반 엣지 디바이스(스마트폰, IoT) 등에서는 GPU 없는 AI가 오히려 더 적합한 구조가 될 수 있다.

향후에는 AI 전용 가속기(NPU, Edge TPU), 칩 설계의 이기종 통합(heterogeneous computing), 소프트웨어의 초경량 최적화가 결합되며, "AI는 반드시 GPU가 필요하다"는 인식은 점차 무너질 것이다.

GPU 없이도 존재할 수 있는 AI, 그것은 단지 가능성이 아니라 이미 시작된 현실이다.