

AI는 GPU 없이 존재할 수 있는가?

8-301-18
이원규

COMPUTER HARDWARE
&
INDUSTRY PERSPECTIVE

1. 서론

인공지능(AI) 기술의 발전은 GPU(그래픽 처리 장치)의 진보와 함께 이루어져 왔다. 딥러닝, 특히 대규모 언어 모델(LLM)의 학습과 추론에는 막대한 병렬 연산이 필요하며, 이는 전통적으로 GPU가 담당해온 역할이다. 그러나 최근 들어 GPU 가격 상승, 전력 소모 문제, 접근성의 한계로 인해 **"GPU 없이 AI는 가능한가?"**라는 질문이 제기되고 있다. 이 레포트에서는 GPU 없는 AI의 가능성과 그 대안으로 주목받는 **NPU(Neural Processing Unit)**의 현재와 미래를 중심으로 분석한다.

2. GPU가 AI에 중요한 이유

GPU는 수천 개의 코어를 통해 대규모 병렬 연산을 수행할 수 있으며, 이는 딥러닝 모델의 학습(Training)과 추론(Inference) 모두에서 필수적이다. 특히 GPT, BERT, LLaMA와 같은 대규모 모델에서는 수백 GB의 연산 데이터를 빠르게 처리해야 하므로, 고속 메모리 대역폭과 연산 능력을 갖춘 GPU가 사실상 유일한 선택지였다.

3. GPU 없이 AI가 가능한 영역

- ☒ 추론(Inference)만 수행할 경우, GPU 없이도 가능
이미 학습된 모델을 사용한다면, 연산량이 상대적으로 적고 CPU나 NPU를 통해 수행 가능
예: 음성 인식, 얼굴 인식, 텍스트 요약 등 경량 추론 모델
- ☒ 학습(Training)은 GPU 없이 현실적으로 불가능
역전파(Backpropagation), 가중치 업데이트, 대규모 데이터 배치 처리가 필요
CPU 또는 NPU 단독으로는 연산 시간, 메모리 사용량, 전력 소모 측면에서 비효율적

4. GPU의 대안: NPU의 과거와 현재

◇ 과거

2017년 Huawei Kirin 970: 세계 최초의 스마트폰용 NPU
Apple A12 Bionic, Google Pixel Visual Core 등 추론 전용 NPU 등장

◇ 현재

고속 양자화 모델 처리, ONNX 지원, AI PC용 NPU 확산
주요 NPU 플랫폼: Apple Neural Engine, Qualcomm Hexagon, Intel NPU (Meteor Lake),
Google Edge TPU

플랫폼	TOPS(이론 연산량)	사용 환경	추론 실용성
Apple M2	15.8	macOS, iOS	높음
Qualcomm Hexagon	45+	Android	제한적
Intel AI Boost	~ 48	Windows	미성숙
Google Edge TPU	~ 4	IoT	매우 제한

5. LLM 추론 관점에서 본 NPU의 현실적인 가능성

☒ 가능 시나리오

이미 학습된 LLaMA, Mistral 등의 7B 이하 소형 모델

양자화된 모델 (INT4, INT8 등) 기반

추론 위주의 로컬 실행 환경 (예: 오프라인 챗봇)

☒ 불가능 또는 비효율적 시나리오

GPT-3/4, LLaMA 13B+, Gemini 등 중대형 모델

메모리 대역폭 부족, VRAM 미지원, 도구 생태계 부재로 실행 불가 또는 성능 저하

6. 왜 Apple NPU만 주로 언급되는가?

Apple Neural Engine은 NPU 중에서도 실제 LLM 추론에 가장 실용적인 플랫폼으로 평가받는다.

그 이유는 다음과 같다:

요소 설명

☒ 공유 메모리(UMA) CPU/GPU/NPU가 같은 메모리를 사용 → 대역폭 병목 없음

☒ Metal 지원 llama.cpp LLaMA 모델을 NPU 또는 GPU를 통해 실행 가능

☒ 소프트웨어 통합 Core ML, Metal, ONNX 등 Apple 생태계 최적화

△ 경쟁 플랫폼(NPU)

Qualcomm, Intel NPU는 높은 이론 성능에도 불구하고 LLM 실행 사례 거의 없음

다시 말해, 절대적인 연산 성능보다도, 실제 사용 가능성, 개발 생태계, 모델 호환성 측면에서 Apple NPU가 유일하게 LLM 로컬 추론에 활용 가능한 NPU인 셈이다.

7. 결론

AI는 GPU 없이도 '부분적 존재'는 가능하다.

특히 경량 추론, 또는 경량 LLM 로컬 실행에 한해서는 CPU나 NPU를 통해 운영할 수 있다.

그러나 모델 학습, 중대형 모델 추론, 고속 응답 처리 등 고성능 연산이 필요한 대부분의 AI 작업에서는 여전히 GPU가 사실상 필수적이다.

즉, AI는 GPU 없이 생존은 가능하지만, '비효율적이며 제약이 크다'.

NPU가 GPU를 완전히 대체하려면 범용성, 메모리 대역폭, 소프트웨어 생태계 모두에서 큰 도약이 필요하다.