



AI는 GPU 없이 존재할 수 있는가 ?

8기-23 정승민

서론

인공지능의 구현 방식은 시대에 따라 큰 변화를 거쳐왔습니다. 초기의 AI 시스템은 주로 규칙과 논리에 기반한 **심볼릭 AI** 방식으로 개발되었으며, **한정된 연산 자원(CPU)** 을 활용해 동작하였습니다. 당시에는 방대한 데이터를 학습시키기보다 사람의 지식을 기호와 규칙으로 프로그램에 직접 넣는 방식이었기 때문에, 현재와 같은 막대한 연산량이 필요하지 않았습니다. 20세기 중반 **앨런 튜링**의 아이디어와 함께 시작된 초기 AI 연구는 체스 게임, 퍼즐 풀이, 대화 흉내(심심이, 엘리자) 등 논리적 추론이나 규칙 기반 대화에 집중하였고, 이들은 비교적 단순한 알고리즘으로도 구현 가능했습니다. 그러나 2010년대를 전후하여 딥러닝을 비롯한 데이터 기반 AI 기법이 부상하면서, 대량의 연산을 빠르게 처리할 수 있는 **GPU**와 같은 병렬 가속기의 중요성이 대두되었습니다. 해당 레포트에는 GPU없이도 AI는 존재했으나, 현대 **대화형 AI**에는 **GPU**혹은 **가속기가 필수** 라는 주제를 중심으로, 시대별 AI 연산 구조의 변천과 그 이유를 살펴보고자 합니다.

본론

튜링 시대와 심볼릭 AI의 등장 (CPU 중심)

앨런 튜링이 활동하던 1940 ~ 50년대부터 20세기 후반까지는, 오늘날과 같은 고성능 병렬 하드웨어는 존재하지 않았습니다. 초기 컴퓨터들은 오로지 **CPU**만으로 구성되어있었고, 연산 속도나 메모리 용량도 지금과 비교하면 극도로 제약적이었습니다. 이러한 환경에서도 초기 AI연구자들은 "기계가 생각할 수 있는가?" 라는 질문에 도전하며, 인간의 사고를 흉내내는 프로그램을 만들기 시작했습니다. 이 시기의 AI는 **기호처리**와 **논리 추론**에 기반한 알고리즘, 이른바 **고전적 AI (GOFAI)**에 집중했습니다. 예를 들어, 1950-60년대에 개발된 일반 문제 해결기나 1966년의 대화 시뮬레이션 프로그램 (엘리자)는 미리 정의된 규칙과 패턴 매칭을 활용하여 작동했는데, 복잡한 부동소수점 행렬 연산보다는 문자열 처리와 조건 분기에 가깝기 때문에 CPU만으로도 충분히 실행될 수 있었습니다. 실제로 심볼릭 AI 기법들은 GPU 연산이 필수적인 현대의 생성형 AI에 비해 연산 자원 요구량이 훨씬 적었고, 표준 CPU 상에서도 원활하게 동작할 수 있었습니다. **이러한 프로그램들은 대개 별도의 "훈련" 과정 없이 사람의 지식을 규칙으로 입력했기에 대규모 병렬 연산이 필요하지 않았던 것입니다.** 요약하면, 초창기 AI는 문제를 사람처럼 논리적으로 푸는 알고리즘 위주였고, 당시의 CPU 중심 컴퓨팅으로도 구현이 가능했던 것입니다.

딥러닝의 부상과 GPU의 혁신 (2010년대 이후)

2000년대에 들어서면서, 특히 2010년대 초반에 AI 분야는 큰 전환점을 맞이합니다. 과거에도 인공신경망에 대한 연구가 없었던 것은 아니지만, 연산 자원의 한계로 인해 깊은 신경망을 충분히 활용하지 못했습니다. 예를 들어 1980년대까지 기초적인 신경망 연구가 있었지만, 당시 CPU로는 수만 개 수준의 인공 뉴런도 실시간으로 구동하기 어려웠습니다. 전통적인 CPU는 **복잡한 논리 연산**에는 강점이 있었지만, **대규모 행렬 연산을 반복 수행**하는 데에는 적합하지 않았기 때문입니다. 이 연산 능력 문제는 2000년대 후반 GPU의 등장으로 해결하기 시작했습니다. **GPU는 원래 그래픽 처리용으로 개발된 프로세서로, 수천 개의 코어를 활용한 병렬 연산에 특화되어 있었습니다.**

2006년 엔비디아가 CUDA라는 GPU 범용 연산 플랫폼을 공개하면서, 과학자들은 GPU를 그래픽 이외의 일반 연산에도 활용하기 시작했습니다. 그 결과, 딥러닝 분야에서 GPU 활용이 가속화되었고, 불과 몇 년 만에 연구 양상이 바뀌었습니다. 대표적으로, 2012년 ImageNet 이미지 인식 대회에서 우승을 차지한 AlexNet 모델은 GPU 두 대를 활용한 대형 **합성곱신경망(CNN)**으로 압도적인 정확도를 기록하였습니다. 이 모델은 약 6천만 개 이상의 파라미터를 가진 매우 깊은 신경망이었지만, 대용량 이미지 데이터셋을 2개의 GPU로 분산 병렬 학습시켜 기존 기법을 큰 격차로 누르고 승리했습니다. 이 사례는 딥러닝의 잠재력을 입증한 사건이었고, 이를 계기로 구글 등 IT 대기업들이 본격적으로 딥러닝 연구에 투가하여 딥러닝 혁명이 촉발되었습니다. **GPU의 등장은 수십 년간 이론으로만 존재하던 딥러닝을 현실화시켰고, 복잡한 모델을 실제로 학습시키고 구동하는 것을 가능하게 하였습니다.**

CPU만으로 가능한 사례와 그 한계 (TINY 모델)

GPU 등장 이후에도 CPU만으로 동작하는 AI 모델이나 시스템이 완전히 사라진 것은 아닙니다. 경량화된 딥러닝 기술은 엣지 디바이스나 모바일 환경에서도 활용될 수 있도록 발전했으며, 이를 통칭해 **TinyML**이라고 부르기도 합니다. 해당 분야에서는 마이크로 컨트롤러 같이 극도로 제약된 하드웨어에서도 동작할 수 있도록 모델 크기와 연산량을 극소화 합니다. 예를 들어, 소형 음성 인식이나 간단한 센서 데이터 분류 등의 작업을 위해 딥러닝 모델을 활용할 때는, 모델의 복잡도를 낮추어 모델 크기를 10배 이상 줄이고 연산량을 수배 감소시키는 기법들이 사용됩니다. 이렇게 하면 수십 KB 메모리와 낮은 클럭으로 CPU만으로 제한적인 AI 기능을 수행 할 수 있습니다. **하지만 이런 경량화는 모델의 성능이나 표현력이 GPU기반으로 하는 AI보다는 저하된다는 점이 있습니다.** TinyML 같은 모델들은 효율을 위해 모델 용량을 줄였기 때문에 대형 모델만큼 성능을 내기 어렵습니다. 예를 들어 약 300억 매개변수에 달하는 최신 언어 모델을 8코어 CPU 서버에서 실행하였을 때, 토큰당 출력 속도가 초당 0.04개 수준에 불과했다는 보고가 있습니다. 이는 한 글을 생성하는데 25초가 걸리는 셈으로, 실제 대화형 AI서비스로는 도저히 쓸 수 없는 지연 시간

입니다. 반면 GPU를 사용하면 동일 모델에서도 초당 수 개 이상의 토큰 생성을 기대할 수 있어서, CPU 대비 10배 이상 빠르게 추론을 수행할 수 있다고 합니다. 결국 파라미터 수가 방대하고 연산량이 많은 현대의 딥러닝 모델은 CPU만으로는 효율적으로 한계가 명확합니다.

결론

과거 심볼릭 AI 시대의 인공지능은 상대적으로 간단한 연산과 규칙 기반 처리로도 구현이 가능하며, 한정된 CPU 자원만으로도 성과를 낼 수 있었습니다. 그러나 **딥러닝의 시대에 들어서면서 AI 모델의 능력이 데이터와 연산량에 비례해 향상된다는 사실이 명백해졌고, 대규모 병렬 연산을 처리할 수 있는 하드웨어 없이는 최첨단 AI를 구현하기 어렵게 되었습니다.** 오늘날 우리가 접하는 대화형 AI는 수억 ~ 수천개의 파라미터를 가진 거대 신경망 모델로 구동되며, **이를 원활히 훈련하고 실시간 추론하기 위해서는 GPU나 TPU등의 가속기가 필수적입니다.** GPU는 다수의 코어로 병렬 처리를 수행하여 CPU로는 수주 걸릴 작업을 수일 이내로 단축시키고, 추론 시에도 지연을 크게 줄여줍니다. 또한 구글 TPU와 같은 ASIC 기반 AI 전용 칩은 특정 딥러닝 연산에 특화되어 전력 대비 성능을 높여주므로, 대규모 AI 서비스의 운영 비용과 에너지 효율 개선에 핵심적인 역할을 하고 있습니다.

결론적으로 GPU 없이도 AI는 존재했으나, 현대의 대화형 AI에는 GPU 혹은 전용 가속기가 필수적이라는 명제는 기술적 현실을 잘 반영합니다. 과거의 접근법으로 제한된 자원 내에서 동작하는 작은 AI를 만드는 것도 여전히 의미가 있지만, 사용자와 상호작용하며 방대한 지식을 실시간으로 처리하는 오늘날의 AI에 요구되는 성능 수준을 만족하려면 고성능 병렬 하드웨어의 도움은 필연적입니다. 앞으로도 모델 규모가 커지고 응용 범위가 넓어질수록, 하드웨어 가속기는 AI 발전의 중요한 축으로 남을 것이며, 소프트웨어적으로도 효율을 높이는 연구는 가속기와 조화를 이루며 병행 발전 할 것 입니다. **AI 역사에서 연산 자원의 중요성은 계속 증명되어 왔고, 적절한 연산도구 없이는 획기적인 AI도 없다는 사실을 간과해야 합니다.**

참고 문헌

NVIDIA Blog, What Is a Transformer Model?(Rick Merritt, 2022)

HuggingFace Forum, Expected speeds for CPU inference?(2023)

Unite.AI, TinyML: Applications, Limitations, and Its Use in IoT & Edge Devices(2023)

한국경제매거진, "인터넷도, GPU도 필요 없다"... 한국형 AI, 글로벌 시장 흔든다(2025)